

Les chiffres affichés sont-ils justes ?

Phase exécutée : Phase 1 — cohérence interne de DAMIR · 19/08/2026 à 10:09 · branche `heads/v2` · commit `5d25588`

Le contrôle décisif est conforme. Le cube compact — celui que l'application interroge — est fidèle au cube brut de 11 Go **cellule par cellule** sur les 5 762 787 clés : aucune clé manquante ni surnuméraire. Le pire écart relatif est de **6,9e-13** et le pire écart absolu de **2,4e-07 €** — l'ordre de grandeur de l'arrondi machine. Les volumes sont identiques au bit près.

Aucun défaut de calcul n'a été trouvé sur les 13 contrôles de cette phase. 6 contrôles portent un « écart expliqué » : le calcul est juste, mais le résultat demande une précaution de lecture, écrite en clair.

La précaution la plus importante : 16,7 % du montant remboursé — 234,8 Md€ — porte une région « Non renseignée ». Additionner les régions nommées donne 1 170,2 Md€ là où le total national est de 1 405,0 Md€. L'application n'escamote rien : la modalité est offerte et étiquetée. Le risque est que le lecteur, lui, l'oublie.

13 CONTRÔLES	7 CONFORMES	6 ÉCARTS EXPLIQUÉS	0 DÉFAUTS	0 EN ATTENTE
-----------------	----------------	-----------------------	--------------	-----------------

Comment lire ce rapport

Chaque ligne du tableau est un contrôle. La colonne « **comment la référence est obtenue** » est celle qui décide si le contrôle vaut quelque chose : une vérification qui demanderait sa réponse au code qu'elle teste ne prouverait rien. Ici, toutes les valeurs attendues viennent de **SQL écrit à la main** directement sur les fichiers de données, sans passer par une seule fonction de l'application.

Les quatre verdicts, sans nuance intermédiaire.

VERDICT	CE QU'IL SIGNIFIE
Conforme	Écart nul, ou dans la tolérance déclarée avant l'exécution.
Écart expliqué	Divergence réelle, dont la cause est identifiée et écrite. Le calcul est juste ; c'est la lecture qui demande une précaution.
Défaut	L'application se trompe. L'écran touché et l'ampleur sont décrits.
En attente	Référence indisponible, ou contrôle impossible à écrire sans circularité.

Les tolérances, déclarées avant l'exécution

NATURE	SEUIL	POURQUOI
Effectifs, comptages	exact	Ce sont des entiers. Aucun mécanisme numérique ne peut en changer la valeur.
Sommes de montants	1e-9 relatif	L'accumulation flottante sur 5,76 M lignes produit ~5e-13 ; mesuré : 3,8e-13. Le seuil est mille fois au-dessus du bruit, et mille fois en dessous de toute erreur de logique.

NATURE	SEUIL	POURQUOI
Ratios	1e-8 relatif	L'erreur d'un quotient cumule celle de ses deux termes.
Plancher absolu	1e-6 €	Sous le millionième d'euro, aucune grandeur comptable ne se distingue.
Références externes	aucune	Un écart n'y est jamais toléré : il est expliqué, ou il reste un défaut.

Un amendement, déclaré plutôt que passé sous silence. Le premier jet du harnais comparait en relatif seul et classait le contrôle I-06c en *défaut* : « 300 % d'écart ». Vérification faite, ces écarts portaient sur des cellules dont la somme vaut $4,4 \times 10^{-16}$ € — des résidus d'arrondi nés de l'annulation entre un débit et un crédit. Rapporter un tel écart à un tel dénominateur ne mesure rien.

Le critère combine désormais un plancher absolu et la tolérance relative, **laquelle n'a pas bougé**. Ce n'est pas un seuil relevé pour faire passer une ligne : c'est une métrique corrigée. Les deux mesures — écart absolu et écart relatif — sont publiées côte à côte pour que le lecteur juge lui-même.

Le tableau des contrôles

RÉF	CONTRÔLE	COMMENT LA RÉFÉRENCE EST OBTENUE	OBTENU	ÉCART	VERDICT
I-01	Σ des modalités de « region » = total, et poids du résidu	SQL manuel sur le Parquet compact, sans `cube_where` ni aucune fonction du produit	1 405 038 187 493,9734	2,90e-14	Écart expliqué
I-02	Σ des modalités de « age » = total, et poids du résidu	SQL manuel sur le Parquet compact, sans `cube_where` ni aucune fonction du produit	1 405 038 187 493,9788	3,30e-14	Écart expliqué
I-03	Σ des modalités de « sexe » = total, et poids du résidu	SQL manuel sur le Parquet compact, sans `cube_where` ni aucune fonction du produit	1 405 038 187 493,9761	3,11e-14	Écart expliqué
I-04	Σ des grands postes, « Autres » compris, = total du cube	SQL manuel : jointure gauche sur `prs_nat_transco.csv`, COALESCE écrit à la main	1 405 038 187 493,9744	2,99e-14	Conforme
I-05	Cascade : Σ postes = grand poste, Σ sous-postes = poste, Σ prestations = sous-poste	SQL manuel, agrégations parent et enfant calculées séparément puis rapprochées	Σ enfants	1,17e-14	Conforme
I-06a	Compact contre brut — total, mesure par mesure	deux SQL manuels, un par fichier Parquet ; aucun code du produit	compact	3,75e-13	Conforme
I-06b	Compact contre brut — par année × mesure	idem, agrégé à l'année de soins	compact	5,56e-14	Conforme
I-06c	Compact contre brut — cellule par cellule, sur la clé complète (8 colonnes)	jointures externes entre les deux Parquet agrégés à la même clé ; SQL manuel	0 clé(s) en désaccord · 0 cellule(s) hors tolérance	6,93e-13	Conforme
I-07	`cube_where` du produit contre un WHERE écrit à la main (8 scénarios)	SQL manuel, prédicat rédigé à la main pour chaque scénario ; `cube_where` fournit la valeur *testée*, jamais l'attendue	prédicat du produit	2,17e-16	Conforme

RÉF	CONTRÔLE	COMMENT LA RÉFÉRENCE EST OBTENUE	OBTENU	ÉCART	VERDICT
I-08	Codes `prs_nat` non couverts par la transcodification : nombre et poids	SQL manuel, jointure gauche sur `prs_nat_transco.csv` puis comptage des orphelins	0 code(s)	0,000 %	Conforme
I-09	« Autres », `__other__` et « Reste du périmètre » ne se confondent jamais	SQL manuel sur la transcodification ; lecture du code pour les deux replis	deux le sont ; la troisième est indiscernable du repli	—	Écart expliqué
I-10	Origine des montants négatifs de « Autres »	SQL manuel, décomposition somme à somme `SUM(rem) - SUM(rem_neg)`	12/12 année(s)	0	Écart expliqué
I-11	Valeurs absentes (NULL) dans les colonnes de mesure	SQL manuel, comptage direct par colonne sur le Parquet compact	3 colonne(s) au-delà de 1 %	—	Écart expliqué

Ce que chaque contrôle a trouvé

I-01 — Σ des modalités de « region » = total, et poids du résidu

Référence obtenue par : SQL manuel sur le Parquet compact, sans `cube\_where` ni aucune fonction du produit

14 modalités, aucune ligne d'agrégat : le total national **est** la somme, et l'additivité est exacte (écart 2.90e-14).

Le point qui mérite l'attention est ailleurs. Le résidu « Non renseignée » pèse 234 847 172 300,0404 € sur 1 405 038 187 493,9326 €, soit **16,715 %**. Additionner les seules modalités nommées donne 1 170 191 015 193,8921 € — il manque exactement ce résidu. La modalité est bien offerte et étiquetée par l'application ; le risque n'est pas qu'elle soit cachée, mais qu'un lecteur additionne les autres et croie tenir le total.

I-02 — Σ des modalités de « age » = total, et poids du résidu

Référence obtenue par : SQL manuel sur le Parquet compact, sans `cube\_where` ni aucune fonction du produit

9 modalités, aucune ligne d'agrégat : le total national **est** la somme, et l'additivité est exacte (écart 3.30e-14).

Le point qui mérite l'attention est ailleurs. Le résidu « Âge inconnu » pèse 19 415 776 474,6799 € sur 1 405 038 187 493,9324 €, soit **1,382 %**. Additionner les seules modalités nommées donne 1 385 622 411 019,2524 € — il manque exactement ce résidu. La modalité est bien offerte et étiquetée par l'application ; le risque n'est pas qu'elle soit cachée, mais qu'un lecteur additionne les autres et croie tenir le total.

I-03 — Σ des modalités de « sexe » = total, et poids du résidu

Référence obtenue par : SQL manuel sur le Parquet compact, sans `cube\_where` ni aucune fonction du produit

4 modalités, aucune ligne d'agrégat : le total national **est** la somme, et l'additivité est exacte (écart 3.11e-14).

Le point qui mérite l'attention est ailleurs. Le résidu « Non renseigné et Inconnu » pèse 17 062 522 398,9300 € sur 1 405 038 187 493,9324 €, soit **1,214 %**. Additionner les seules modalités nommées donne 1 387 975 665 095,0024 € — il manque exactement ce résidu. La modalité est bien offerte et étiquetée par l'application ; le risque n'est pas qu'elle soit cachée, mais qu'un lecteur additionne les autres et croie tenir le total.

I-04 — Σ des grands postes, « Autres » compris, = total du cube

Référence obtenue par : SQL manuel : jointure gauche sur `prs\_nat\_transco.csv`, COALESCE écrit à la main

19 grands postes. « Autres » (prestations sans correspondance dans la transcodification) : -8 049 289 616,5700 €.

I-05 — Cascade : Σ postes = grand poste, Σ sous-postes = poste, Σ prestations = sous-poste

Référence obtenue par : SQL manuel, agrégations parent et enfant calculées séparément puis rapprochées

158 comparaisons · pire écart absolu 1.48e-03 · pire écart relatif 1.17e-14 (sous-poste de « Consultations / Visites ») · 2 valeur(s) absente(s) · 0 hors tolérance

I-06a — Compact contre brut — total, mesure par mesure

Référence obtenue par : deux SQL manuels, un par fichier Parquet ; aucun code du produit

7 comparaisons · pire écart absolu 5.27e-01 · pire écart relatif 3.75e-13 (rem) · 0 hors tolérance

- `rem` — brut 1 405 038 187 493,4050, compact 1 405 038 187 493,9324, écart 3.75e-13
- `dep` — brut 1 601 792 223 029,3628, compact 1 601 792 223 029,8145, écart 2.82e-13
- `depas` — brut 111 499 127 051,3756, compact 111 499 127 051,3620, écart 1.22e-13
- `qte` — brut 133 320 833 455, compact 133 320 833 455, écart 0.00e+00
- `rem_ref` — brut 1 280 885 049 724,9426, compact 1 280 885 049 725,0500, écart 8.39e-14
- `bse_ref` — brut 1 289 338 934 189,8071, compact 1 289 338 934 189,8650, écart 4.49e-14
- `rem_neg` — brut -43 502 681 794,0320, compact -43 502 681 794,0304, écart 3.63e-14

I-06b — Compact contre brut — par année × mesure

Référence obtenue par : idem, agrégé à l'année de soins

84 comparaisons · pire écart absolu 7.61e-03 · pire écart relatif 5.56e-14 (rem 2021) · 0 hors tolérance

I-06c — Compact contre brut — cellule par cellule, sur la clé complète (8 colonnes)

Référence obtenue par : jointures externes entre les deux Parquet agrégés à la même clé ; SQL manuel

0 clé absente du compact, 0 en trop. Sur les 7 mesures, le pire écart **absolu** entre une cellule du brut et la même cellule du compact est de **2.38e-07 €**, et le pire écart **relatif** — mesuré sur les seules cellules dépassant le plancher de 1e-06 € — de **6.93e-13**. C'est exactement l'ordre de grandeur de l'accumulation flottante prévu en Phase 0 ($\sqrt{n} \cdot \epsilon \approx 5e-13$). `qte` est identique au bit près. **Le compact est fidèle au brut.**

- `rem` — 5 762 787 cellules · pire écart absolu 2.38e-07 € · pire écart relatif 2.84e-13 · 0 hors tolérance
- `dep` — 5 762 787 cellules · pire écart absolu 5.96e-08 € · pire écart relatif 6.93e-13 · 0 hors tolérance
- `depas` — 5 762 787 cellules · pire écart absolu 5.96e-08 € · pire écart relatif 6.95e-14 · 0 hors tolérance
- `qte` — 5 762 787 cellules · pire écart absolu 0.00e+00 € · pire écart relatif 0.00e+00 · 0 hors tolérance
- `rem_ref` — 5 762 787 cellules · pire écart absolu 2.38e-07 € · pire écart relatif 2.11e-13 · 0 hors tolérance
- `bse_ref` — 5 762 787 cellules · pire écart absolu 5.96e-08 € · pire écart relatif 1.55e-13 · 0 hors tolérance
- `rem_neg` — 5 762 787 cellules · pire écart absolu 1.19e-07 € · pire écart relatif 6.50e-16 · 0 hors tolérance

I-07 — `cube\_where` du produit contre un WHERE écrit à la main (8 scénarios)

Référence obtenue par : SQL manuel, prédicat rédigé à la main pour chaque scénario ; `cube\_where` fournit la valeur *testée*, jamais l'attendue

8 comparaisons · pire écart absolu 6.10e-05 · pire écart relatif 2.17e-16 (toutes les régions listées = pas de filtre) · 0 hors tolérance

- période seule, 2018–2020 — manuel 357 198 804 583,1324 = produit 357 198 804 583,1324
- une région — manuel 165 238 548 535,4804 = produit 165 238 548 535,4804
- trois régions — manuel 393 323 861 538,5911 = produit 393 323 861 538,5912
- un sexe — manuel 651 093 808 067,4810 = produit 651 093 808 067,4810
- deux tranches d'âge — manuel 264 951 287 081,3328 = produit 264 951 287 081,3328
- région × sexe × âge — manuel 975 959 689,8200 = produit 975 959 689,8200
- ALD seulement — manuel 564 185 935 943,6730 = produit 564 185 935 943,6730
- toutes les régions listées = pas de filtre — manuel 140 857 153 745,4104 = produit 140 857 153 745,4104

I-08 — Codes `prs\_nat` non couverts par la transcodification : nombre et poids

Référence obtenue par : SQL manuel, jointure gauche sur `prs\_nat\_transco.csv` puis comptage des orphelins

0 code sur 1 342 n'est sans correspondance, et aucune ligne de transcodification n'a de grand poste vide. La couverture est totale, et le repli `COALESCE(..., 'Autres')` ne se déclenche jamais sur ces données.

- « Autres » — 90 codes · -8 049 289 616,5700 €
- « Autres Postes » — 20 codes · 2 614 214 765,2300 €

I-09 — « Autres », `\_\_other\_\_` et « Reste du périmètre » ne se confondent jamais

Référence obtenue par : SQL manuel sur la transcodification ; lecture du code pour les deux replis

Le document de référence décrit « Autres » comme les prestations sans correspondance dans la transcodification. Ce n'est pas ce qui se passe. « Autres » est un **grand poste nommé** de la nomenclature — 90 codes, -8 049 289 616,5700 € — et la nomenclature porte en outre un « Autres Postes » distinct. Le repli du `COALESCE` est aujourd'hui vide.

Il en découle un **risque latent**, qui ne produit aujourd'hui aucun chiffre faux : le repli et la catégorie réelle portent **la même étiquette**. Si un code venait à sortir de la transcodification — une nomenclature qui évolue, un millésime de plus — son montant se fondrait dans le grand poste « Autres » sans que rien ne le signale, et « Autres » cesserait d'être ce que la nomenclature dit qu'il est.

Les deux autres notions, elles, sont bien disjointes : `__other__` est une sentinelle préfixée, « Reste du périmètre » un complément de sélection. Ni l'une ni l'autre ne peut entrer en collision avec une chaîne de donnée.

I-10 — Origine des montants négatifs de « Autres »

Référence obtenue par : SQL manuel, décomposition somme à somme `SUM(rem) - SUM(rem_neg)`

12 année(s) où « Autres » affiche un remboursé négatif. Sur **12 d'entre elles**, le remboursé hors régularisations reste **positif** : le signe négatif vient donc entièrement des régularisations (`rem_neg`), qui sont une composante du cube et non un artefact d'agrégation. **Comportement légitime, à documenter — pas un défaut à corriger.**

- **2014** — remboursé -30 671 828,6100 € = régularisations -45 584 477,6500 € + remboursements hors régularisations 14 912 649,0400 €, sur 43 codes
- **2015** — remboursé -639 807 805,5600 € = régularisations -677 198 778,4400 € + remboursements hors régularisations 37 390 972,8800 €, sur 46 codes
- **2016** — remboursé -636 547 104,4500 € = régularisations -674 971 624,1300 € + remboursements hors régularisations 38 424 519,6800 €, sur 46 codes
- **2017** — remboursé -646 910 118,1600 € = régularisations -683 492 296,5100 € + remboursements hors régularisations 36 582 178,3500 €, sur 47 codes
- **2018** — remboursé -663 962 680,4700 € = régularisations -685 476 918,9200 € + remboursements hors régularisations 21 514 238,4500 €, sur 45 codes
- **2019** — remboursé -666 476 364,1400 € = régularisations -688 416 277,1500 € + remboursements hors régularisations 21 939 913,0100 €, sur 49 codes
- **2020** — remboursé -670 848 547,5600 € = régularisations -688 015 966,8500 € + remboursements hors régularisations 17 167 419,2900 €, sur 47 codes
- **2021** — remboursé -768 807 376,4800 € = régularisations -786 031 544,3400 € + remboursements hors régularisations 17 224 167,8600 €, sur 49 codes
- **2022** — remboursé -731 996 790,9400 € = régularisations -755 713 358,1200 € + remboursements hors régularisations 23 716 567,1800 €, sur 56 codes
- **2023** — remboursé -682 062 643,4300 € = régularisations -723 520 725,5500 € + remboursements hors régularisations 41 458 082,1200 €, sur 57 codes
- **2024** — remboursé -894 361 847 € = régularisations -1 076 576 155,3100 € + remboursements hors régularisations 182 214 308,3100 €, sur 60 codes
- **2025** — remboursé -1 016 836 509,7700 € = régularisations -1 204 234 534,4700 € + remboursements hors régularisations 187 398 024,7000 €, sur 61 codes

I-11 — Valeurs absentes ('NULL') dans les colonnes de mesure

Référence obtenue par : SQL manuel, comptage direct par colonne sur le Parquet compact

L'absence est massive et parfaitement normale — mais il faut la connaître pour ne pas écrire de contrôle faux.

`rem_ref` manque sur 50,9% des lignes, `bse_ref` manque sur 50,9% des lignes, `rem_neg` manque sur 67,5% des lignes.

Une base de remboursement absente (`bse_ref`, `rem_ref`) signifie qu'il n'y en a pas — une prestation forfaitaire, une indemnité journalière — et non qu'elle vaut zéro. Une régularisation absente (`rem_neg`) signifie qu'il n'y a pas eu de régularisation. Dans les deux cas, `SUM` écarte les absents, ce qui donne le bon total.

La conséquence pratique, apprise à nos dépens : toute décomposition doit se faire **somme à somme** et jamais ligne à ligne. `SUM(rem - rem_neg)` écarte les deux tiers des lignes et se trompe de 68,75 M€ ; `SUM(rem) - SUM(rem_neg)` est juste. Le produit emploie bien la seconde forme.

- `rem` — 6 lignes absentes sur 5 762 787 (0,000%)
- `dep` — 0 lignes absentes sur 5 762 787 (0,000%)
- `depas` — 0 lignes absentes sur 5 762 787 (0,000%)
- `qte` — 0 lignes absentes sur 5 762 787 (0,000%)
- `rem_ref` — 2 930 798 lignes absentes sur 5 762 787 (50,857%)
- `bse_ref` — 2 930 798 lignes absentes sur 5 762 787 (50,857%)
- `rem_neg` — 3 892 606 lignes absentes sur 5 762 787 (67,547%)

Les données auditées

FICHIER	EMPREINTE
cube_damir.parquet	1 091 430 439 o · modifié 2026-07-30 15:22 UTC (non haché : trop volumineux)
cube_damir_compact.parquet	121 948 630 o · sha256 26e201a9cfa55de5
prs_nat_transco.csv	153 189 o · sha256 03dde2813fad7ecf

Le cube brut n'est pas haché : à 1,1 Go, son empreinte cryptographique coûterait plus que l'ensemble des contrôles. Il est identifié par sa taille et sa date.

Ce que cette phase ne dit pas

Cette phase établit que **DAMIR est cohérent avec lui-même**. Elle ne dit pas encore que les chiffres sont *vrais* : cela demande de les confronter à ce que publient l'Assurance Maladie, l'Insee et le CépiDc. Ces valeurs de référence ne peuvent pas être écrites de mémoire — une référence inventée invaliderait l'audit entier — et le poste est hors ligne par principe. Elles restent donc à fournir.

Restent également à mesurer : la **parité entre les quatre écrans** qui calculent les mêmes indicateurs par des chemins différents, les invariants et cas limites, et l'affichage. Une piste est déjà repérée et attend d'être chiffrée : dans l'écran Extraire, cocher « Ticket modérateur » pourrait modifier la valeur du « Montant remboursé » affiché à côté.